

교통정보 CCTV를 활용한 인공지능 기반 포트홀 탐지 기술 개발*

AI-Based Pothole Detection Using Traffic Surveillance CCTV

임원섭** · 민철규*** · 최영환****

Won Seop Im** · Chul Gyu Min*** · Young Hwan Choi****

Abstract

As road infrastructure ages, potholes tend to form more frequently, resulting in increased vehicle damage and traffic accidents that pose significant societal challenges. Existing pothole detection methods, which use vehicle-mounted sensors or drones, suffer from limited coverage and high deployment costs. This study proposes an AI-based automated pothole detection model utilizing nationwide traffic surveillance CCTV. The model employs YOLOv8 with instance segmentation for precise pothole detection and integrates a vehicle tracking algorithm to automatically measure traffic volume. By combining data on pothole size, location, and traffic, the system quantitatively assesses road risk and supports maintenance prioritization. The proposed approach achieves high detection accuracy and real-time processing performance compared to existing methods, contributing to improved efficiency and safety in road infrastructure management.

Keywords: Road Defect, Pothole, Pothole Detection, Traffic Information CCTV, YOLOv8

1. 서론

도로에 발생하는 포트홀(pothole)은 아스팔트 포장 도로에서 지름 15cm 이상, 깊이 2cm 이상의 움푹 패인 형태의 파손을 의미하며, 도로 안전과 차량 운행에 심각한 위협이 된다. 포트홀은 빗물, 염화칼슘 등이 아스팔트 포장 내부로 침투하여 접착력이 약화되고, 차량 하중으로 인해 골재가 탈락하며 발생한다. 국내 도로는 1970년대 이후 본격적으로 건설되어, 2022년 기준 총 연장 114,314km에 달하며, 이중 30년 이상 경과한 노후도로가 51.5%에 이른다(국토교통부, 2022). 도로 노후화로 인해 포트홀 발

생 빈도는 지속적으로 증가하고 있으며, 이에 따른 차량 손상, 인명 피해, 교통사고 등이 사회적 문제로 대두되고 있다(한국도로공사, 2023). 따라서 포트홀을 신속하고 정확하게 탐지하여 선제적으로 유지보수를 수행하는 것은 도로 안전 확보에 있어 필수적인 요소다.

기존의 도로 상태 점검은 인력에 의존한 현장 조사나 수동 촬영을 기반으로 하고 있으며, 시간과 비용이 과다하게 소요된다. 이러한 방식은 포트홀 발생 즉시 대응이 어려워 사고 예방 효과가 제한적이다. 최근 이를 극복하기 위해 영상 기반의 자동 탐지 기술이 활발히 연구되고 있다. 예를 들어, Lee et al.

*본 연구는 중소벤처기업부의 기술개발사업 [RS-2024-00426703] 및 [RS-2025-02313765]의 지원에 의한 연구임.

**경상국립대학교 건설시스템공학과 학부과정(주저자: dnjs9545@naver.com)

***경상국립대학교 건설시스템공학과 학부과정

****경상국립대학교 건설시스템공학과 부교수(교신저자: yh.choi@gnu.ac.kr)

(2023)은 F-RCNN과 Inception-V2 모델을 결합하여 포트홀의 경계와 질감 특징을 활용한 탐지 기법을 제안했다. Kim et al.(2022)은 다양한 컴퓨터 비전 모델의 성능을 비교하고, YOLO 계열 모델이 주간 및 저조도 환경에서 빠르고 높은 정확도를 보이는 반면, R-CNN 계열 모델은 야간 환경에서 우수한 성능을 보임을 확인하였다. 또한, Bhatia et al.(2022)은 열화상 카메라를 활용하여 빛에 의존하지 않고 온도 차이를 통해 포트홀을 탐지하는 방법을 제시하였고, Saisree and Kumaran(2023)은 Mask R-CNN을 적용한 고해상도 항공 이미지 기반 포트홀 탐지 시스템을 개발하였다.

최근 연구들은 인공지능 기술의 발전에 힘입어 YOLOv8, YOLOv7, YOLOv5 등 최신 객체 탐지 모델을 활용하여 포트홀 탐지 성능을 지속적으로 개선하고 있다. Yurdakul and Tasdemir(2025)은 YOLOv8과 RGB-D 데이터를 결합하여 포트홀의 물리적 특성까지 정밀하게 측정 가능한 모델을 제안하였지만, RGB-D 센서의 설치 비용과 범용성 측면에서 한계가 있다. Zanevych et al.(2024)은 YOLOv11에 FPN과 Grad-CAM++을 적용하여 야간 환경에서도 높은 정확도를 확보하였으나, 조명 변화 외에 복잡한 도로 조건에서의 일반화 성능은 제한적이다. Li et al.(2023)은 YOLOv5를 활용한 실시간 포트홀 탐지 모델을 개발했지만, 시간에 따른 포트홀의 변화를 고려하는 동적 분석이 부족하다. Rout et al.(2023)은 저해상도 영상을 ESRGAN을 통해 복원한 후 YOLOv7으로 탐지 정확도를 향상시켰지만, 연산 비용이 증가하며 실시간 처리에 어려움이 존재한다. 또한, Rehan et al.(2023)은 자율주행 차량을 위한 포트홀 탐지 모델을 제안하였으나, 자율주행 차량이 접근 가능한 도로에 국한된다는 한계가 있다. 마지막으로, Safyari et al.(2024)은 포트홀 탐지에 대한 종합적인 리뷰를 통해 최신 기술 동향을 제시했지만, 실제 적용 가능성에 대한 정량적 실험이 부족하다.

이와 같은 최근 연구들은 대부분 차량에 장착된 센서나 드론, 혹은 단일 시점의 카메라 영상에 기반하고 있어 특정 도로 구간만 탐지 가능하거나 설치 및 유지보수 비용이 높은 문제가 있다. 또한 대부분의 연구가 단순 탐지 성능 향상에 집중되어 있어, 포트홀로 인한 사고 위험도를 예측하거나, 도로의 통행량과 결합한 복합적인 분석 기능은 미흡하다. 특히, 포트홀 탐지 이후 어떤 도로가 보다 시급히 보수되어야 하는지에 대한 의사결정 지원 체계는 여전히 부족한 실정이다.

본 연구는 이러한 한계점을 극복하고자 한다. 차량 탑재 센서나 드론 기반의 제한적인 데이터 수집 방식이 아닌, 전국 도로망에 이미 구축된 교통정보 CCTV를 활용하여 포트홀을 탐지하는 방식을 제안한다. CCTV는 고정된 위치에서 광역적인 도로 상태를 모니터링할 수 있어 높은 공간적 확장성을 가지며, 기존 인프라를 활용하기 때문에 경제성이 뛰어나다. 또한, 본 연구는 단순 포트홀 탐지에서 나아가, AI 기반 차량 트래킹 모델을 결합하여 도로 통행량을 자동으로 측정하고, 이를 바탕으로 포트홀 발생 위치와 도로 이용 강도를 종합적으로 분석한다. 이를 통해 포트홀의 위험도를 정량화하고, 보수 우선순위 결정 및 사고 예방을 위한 실질적인 의사결정 지원 도구로 활용 가능한 새로운 접근법을 제시한다.

2. 포트홀 탐지 자동화 기법

본 연구에서 제안하는 교통정보 CCTV를 활용한 포트홀 탐지 자동화 기법은 세 가지 주요 작업(Task)으로 구성된다. 전체적인 흐름도는 Fig. 1과 같이 데이터 세트 구성(Dataset Composition), AI 기반 포트홀 탐지 모델 개발(Development of Pothole Detection Model), 그리고 교통량 측정 모델 개발(Traffic Volume Measurement)로 이루어진다. 데이터 세트 구성은 부족한 학습 데이터 문제를 해결하기 위해 실제 데




Fig. 1. Flowchart of the Automated Pothole Detection Technique

이터를 기반으로 한 모의 시나리오 데이터를 생성하고, 이를 실제 수집 데이터와 결합하여 학습용 데이터 세트를 확보하는 과정이다. 이후 AI 기반 포트홀 탐지 모델은 해당 데이터 세트를 전처리 및 증강하여 YOLO 기반 인스턴스 세그멘테이션 모델을 학습시키고, 실시간 탐지 시스템으로 구현된다. 마지막으로 도로의 교통량 측정 모델은 포트홀 발생 위치에 따른 차량 통행량 정보를 정량화하여 사고 위험도 분석 및 보수 우선순위 결정에 활용된다. 본 연구 과정은 Fig. 1에 나타내었다.

2.1 Dataset 구성

본 연구에서는 도로 표면 결함 중 포트홀(Pothole)을 주요 탐지 대상으로 선정하였다. 학습 데이터는 국토교통부의 교통정보 CCTV Open API와 경찰청 교통정보센터(UTIC)에서 제공하는 오픈소스 데이터를 활용하였다. 그러나 CCTV 기반 포트홀 데이터는 포트홀의 자연 발생 빈도가 낮고, 카메라 해상도나 촬영 각도에 따라 탐지 가능한 영상이 제한적이기 때문에 원활한 모델 학습을 위한 데이터가 절대적으로 부족하다.

이를 해결하기 위해 본 연구는 합성 데이터(Synthetic Data)를 적극적으로 활용하였다. 실제 포트홀의 형상과 질감을 보존하기 위해 포트홀 부분만을 배경이 없는 형태로 추출한 후, 포트홀이 없

는 CCTV 원본 영상에 다양한 위치와 스케일로 합성하였다. 포트홀의 크기는 일반적으로 차선 폭의 약 1/10에 해당하는 10cm~20cm로 설정하고, 개수는 이미지당 1~3개의 포트홀이 삽입되도록 설계하였다. 또한, 포트홀의 회전(Rotation), 크기 변환(Scaling), 밝기 조정(Brightness), 노이즈 추가 등 다양한 변형을 적용하여 데이터의 다양성을 확보하였다. 데이터 품질 측면에서 사용된 CCTV는 평균 1280×720 해상도이며, 촬영 각도는 도로 전체를 포괄할 수 있도록 상부 또는 측면 45도 이내로 설치된 것이 대부분이다. 야간 촬영 시에는 가로등 및 차량 헤드라이트에 의해 조도가 불균형하게 분포한다는 한계가 존재한다. 따라서 조도 변화에 따른 모델 성능 저하를 방지하기 위해 밝기와 대비를 조정한 데이터 증강 Fig. 2와 같이 추가하였다. 데이터셋의 편향성 또한 고려되었다. CCTV 영상 데이터는 주로 도시 주요 도로와 교차로에 설치된 공공 CCTV에서 수




Fig. 2. Process of Generating Simulated Scenarios

집되었기 때문에, 농촌 지역, 산간 도로, 또는 도심 외곽 도로에서 촬영된 데이터는 상대적으로 부족하다. 또한, 수집된 원본 영상의 시간대 분포는 주간 약 70%, 야간 약 30%이며, 기상 조건은 맑음이 60%, 흐림과 비가 각각 약 20%로 편중되어 있다.

이러한 편향을 보완하고 모델의 일반화 성능을 확보하기 위해, 본 연구에서는 부족한 환경(야간, 우천, 악천후, 외곽 도로 등)을 대상으로 실제 촬영 데이터 및 공개 데이터셋을 추가 확보하였으며, 더 나아가 도로 야간 특성을 고려한 조도 보정을 통해 합성 데이터를 생성하여 학습 데이터에 포함시켰다. 합성 데이터의 비중은 전체 학습 데이터의 35%이며, 이는 모델이 다양한 도로 유형과 환경 조건에서도 안정적으로 작동하도록 하기 위한 것이다. 합성 데이터의 성능 기여도를 정량적으로 평가하기 위해 합성 데이터만으로 학습한 모델, 실제 데이터만으로 학습한 모델, 그리고 두 데이터를 결합한 모델로 실험을 수행하였다.

mAP50(mean Average Precision at IoU 0.5)은 객체 탐지(Object Detection) 성능을 평가하기 위한 대표적인 지표로 검출된 객체의 예측 박스와 실제 정답 박스 간의 교차 영역 비율(IoU, Intersection over Union)이 0.5 이상일 때를 정답으로 간주하여 계산한 평균 정밀도(Average Precision, AP)의 평균 값을 의미한다. 여기서 IOU는 두 영역이 얼마나 겹치는지를 수치로 나타낸 값이다. 모델이 예측한 영역이 실제 정답 영역과 얼마나 일치하는지 평가할 때

사용하며, 두 상자가 많이 겹칠수록 IOU 값이 1에 가까워진다.

그 결과, 실제 데이터만으로 학습 시 mean Average Precision at IoU 50%(mAP50)은 78.4%, 합성 데이터만으로는 74.1%, 두 데이터를 결합할 경우 85.2%로 나타나, 합성 데이터가 모델 성능 향상에 실질적인 효과가 있음을 확인하였다.

2.2 AI 탐지 모델 개발

데이터 전처리 과정에서 대략 1000장을 AI모델에 학습할 수 있는 형태로 라벨링 툴(Labelme)을 이용하여 폴리곤 형태로 주석처리 하였다. 그리고 도로표면 결합을 탐지할 AI모델로는 YOLO(You Only Look Once)를 활용하였다. YOLO(Redmon et al., 2016)의 1-stage-detection모델로 정확도(AP)는 상대적으로 낮지만 처리속도(FPS)가 빨라 실시간 탐지에 적합하다는 장점이 있다. 여러 모델 중 YOLOv8으로 선정하였고 매개변수에 따라 Nano, Small, Medium, Large, Extra-large 총 5가지의 확장된 버전이 존재하며 픽셀 단위로 분할이 가능한 Instance Segmentation을 지원한다(Terven et al., 2023). 각 버전별로 COCO데이터세트의 벤치마크 결과는 Table 1과 같으며 본 연구에서는 Small을 사용하였다.

이후 데이터 증강(Data Augmentation) 기법을 사용해 원본 데이터로부터 새 데이터를 만들어 내어 학습 정확도와 효율성을 높여주었다. 데이터 증강의 방법으로는 회전(Rotation), 이동(Translation), 노

Table 1. COCO Dataset Benchmark Results for Versions of YOLOv8

Model (Segment)	mAPbox 50-95	mAPmask 50-95	Speed CPU ONN	Speed A100 TensorRT
Nano	36.7	30.5	96.1	1.21
Small	44.6	36.8	155.7	1.47
Medium	49.9	40.8	317.0	2.18
Large	52.3	42.6	572.4	2.79
Extra-large	53.4	43.4	712.1	4.02

이즈 추가(Noise Addition), 크기 조정(Scaling), 색상 변환(Color Transformation) 총 5개의 방법을 사용하였다.

2.3 AI 기반 차량 트래킹

포트홀 탐지 결과는 도로 위험도 평가로 확장되기 위해 반드시 도로 이용 강도와 결합되어야 한다. 이를 위해 본 연구는 영상 기반 차량 트래킹 모델을 추가로 개발하였다. 차량 트래킹은 YOLOv8 탐지 결과를 기반으로, 프레임 간 바운딩 박스의 위치 변화와 IOU(Intersection over Union) 계산을 통해 이루어진다.

IOU 값이 0.75 이상인 경우 동일 객체로 판단하고, 그렇지 않으면 신규 객체로 인식한다. 이 방식은 중복 카운팅을 효과적으로 방지하면서도 차량 이동 경로를 지속적으로 추적할 수 있도록 한다. Table 2와 같이 트래킹 알고리즘의 성능은 교차로, 터널, 곡선 도로, 악천후 등 다양한 복잡한 환경에서도 검증되었다. 실험 결과, 평균 통행량 측정 오차율은 4.7%로 나타났으며, 이는 기존의 단순 배경 차분 기반 방식의 오차율(약 12.5%)에 비해 상당히 개선된 수치이다. 특히 터널 출입구나 비·눈이 내리는 상황에서도 안정적인 차량 인식 및 트래킹 성능을 유지하였다. IOU 수치에 대한 기준은 Table 2에 나타내었다.

차량 트래킹 기능은 단순히 통행량 측정에 그치지 않고, 차량의 속도 추정과 차종 분류로 확장되었다. 속도는 두 연속 프레임 간 바운딩 박스 중심 좌표의 변화량을 시간당 거리로 환산하여 계산하였고, 차종 분류는 YOLOv8 모델에 추가로 학습시킨 차량 클래

스(승용차, 버스, 트럭) 분류기로 처리하였다. 이를 통해 본 연구는 포트홀의 위치와 크기뿐만 아니라, 해당 도로의 통행량, 평균 속도, 대형차량 비율까지 종합적으로 분석하여 도로 위험도를 정량화할 수 있게 되었다.

결국 본 연구에서 제안하는 포트홀 탐지 자동화 시스템은 단순한 결함 탐지 기능을 넘어, 도로 이용 행태와 결합하여 유지보수 우선순위를 도출하고, 교통 안전성 확보를 위한 실질적인 의사결정 지원 도구로서 활용 가능하다. 이는 기존의 차량 센서 기반 포트홀 탐지 기술이나 드론 기반 탐지 방식이 가지는 공간적 한계와 비용 부담 문제를 효과적으로 극복하는 대안으로 제시될 수 있다.

3. 적용 및 결과

본 연구에서는 교통정보 CCTV를 활용한 포트홀 탐지 및 차량 통행량 측정 모델의 실질적인 성능을 정량적으로 평가하였다. 이를 위해 데이터 구성의 효과성 검증, 포트홀 탐지 정확도 분석, 차량 트래킹 및 통행량 측정 성능 평가, 그리고 위험도 분석 및 오류 원인 규명 등 총 네 가지 단계로 실험을 진행하였다. 본 장에서는 각 단계별 실험 절차와 결과를 체계적으로 제시하며, 본 연구의 실용적 가치와 기존 연구와의 차별성을 구체적으로 설명한다.

3.1 Simulation scenarios 데이터 효과

본 연구는 CCTV 데이터의 한계인 포트홀 발생 빈도 부족 문제를 해결하기 위해 합성 데이터(Synthetic Data)를 생성하여 학습 데이터에 추가하는 방식을 적용하였다. 실제 수집된 도로 영상 데이터는 총 1,000장이었으며, 여기에 합성 데이터를 추가하여 최종적으로 2,000장의 학습 데이터셋을 구성하였다. 합성 데이터는 포트홀의 크기, 위치, 형태, 밝기, 그리고 도로 배경의 다양한 특성을 고려하여 제작되

Table 2. IOU Notation

Sample IOU Score	IOU Threshold
IOU=0.50	>=0.50
IOU=0.75	>=0.75
IOU=0.95	>=0.95




Fig. 3. Changes in the Precision-Recall Curve

었다. 특히 포트홀의 크기는 10~20cm로 설정되었으며, 회전, 밝기 변화, 노이즈 추가 등의 변형을 통해 데이터의 다양성과 일반화 능력을 극대화하였다. 합성데이터를 추가 전후의 예측 정확도는 Fig. 3과 같이 Precision-Recall 곡선에서 변화를 볼 수 있다.

합성 데이터가 모델 성능에 미치는 영향을 확인하기 위해, 합성 데이터가 없는 경우와 포함된 경우로 나누어 성능을 비교 분석하였다. 그 결과, 합성 데이터를 포함하지 않고 학습한 모델은 Precision 84.1%, Recall 79.3%, F1-Score 81.6%, mAP50 78.4%의 성능을 기록하였다. 반면 합성 데이터를 포함한 모델은 Precision 89.7%, Recall 92.9%, F1-Score 91.2%, mAP50 85.2%로 성능이 크게 향상되었으며, 특히 Recall 수치의 상승이 두드러졌다. 이는 포트홀을 놓치는 경우(False Negative)가 현저하게 감소했음을 의미한다. 또한 FPS(Frame Per Second)는 평균 122로 측정되어 실시간 처리 성능도 충분함을 입증하였다.

이러한 결과는 합성 데이터가 데이터 부족 문제 해결 뿐만 아니라, 모델의 일반화 능력 향상에도 크게 기여함을 보여준다. 특히 실제 발생 빈도가 낮은 포트홀 패턴에 대한 학습 효과가 극대화되었다는 점에서 매우 의미 있는 결과이다.

3.2 Pothole Detection 결과

포트홀 탐지 성능을 평가하기 위해 본 연구는 다양한 환경 조건을 반영한 실험 시나리오를 설정하였다.

본 실험은 교통정보 CCTV를 통해 포트홀의 탐지 가능성을 증점적으로 보기 위해 야간 및 악천후 상황을 제외한 맑은 날씨에서 촬영된 영상만을 활용하였다. 또한 카메라의 자세 이동이 없는 CCTV를 활용하였기 때문에 포트홀이 식별 가능한 영상에서 비디오 프레임 추출을 통해 이미지 데이터로 탐지 성능 평가를 진행하였다. 실제 전국의 교통정보 CCTV 3,000대에서 데이터를 고려하여 포트홀이 식별 가능한 영상을 적용하여 제안된 포트홀 탐지 성능을 검증하였다. 이러한 제한된 포트홀 사례는 데이터의 희소성을 다시 한번 입증하는 결과이며, 본 연구의 합성 데이터 기반 접근 방식이 반드시 필요한 이유이기도 하다.

Fig. 4는 연구에 사용된 실제 포트홀이 식별된 원본 이미지와 알고리즘을 통한 포트홀 탐지 결과를 나타낸 것이다. 검증에 사용된 교통정보 CCTV는 지면에서의 높이, 위치, 카메라 자세가 다양하게 구성되었고, 지면에서 높게 설치된 CCTV에서도 포트홀 검출이 가능한 것을 확인할 수 있다. 이는 본 연구의 핵심 목표인 교통정보 CCTV를 통해 포트홀의 탐지가 가능한지에 대한 긍정적인 결과이다.



Fig. 4. Pothole Detection Results Using the Algorithm

제안하는 알고리즘의 포트홀 탐지 성능을 평가하기 위해 모델이 평가해야 하는 요소인 TP(True Positive), FP(False Positive), FN(False Negative)을 이용해 성능평가를 수행한다. 본 연구에서 TP(True Positive)는 포트홀을 정확하게 포트홀로 검출한 것을 의미하고, FP(False Positive)는 포트홀이 아닌 것을 포트홀로 잘못 검출한 것을 의미하고, FN(False Negative)는 실제 포트홀을 탐지하지 못한 것을 의미한다. Table 3은 실제 포트홀 28개가 포함된 교통정보 CCTV 이미지를 통해 성능 평가를 진행한 것이다. Precision(정밀도)는 84.61%이고, Recall(재현율)은 78.57%를 보인다. Table 3은 연구 결과를 정리한 표이다.

탐지 성능을 보다 정밀하게 분석하기 위해 오류 유

형별로 False Positive(FP)와 False Negative(FN)에 대한 상세한 원인 분석을 수행하였다. 분석 결과, FP는 총 5건으로 나타났으며, 이는 대부분 도로 상의 맨홀 뚜껑, 진한 그림자, 또는 유류 얼룩이 포트홀과 유사한 형태로 인식되어 발생하였다. 이러한 오탐지는 주간 시간대의 특정 각도에서 그림자 패턴이 강하게

Table 3. Pothole Detection Results

Category	Value
Total TP	22
Total FP	5
Total FN	6
Precision	84.61%
Recall	78.57%



(a) Real CCTV date



(b) Image after illumination correction


Fig. 5. Comparison of Images before and after Preprocessing for Illumination Correction

드리워지는 경우에서 빈번하게 나타났다. FN은 총 6건으로 기록되었으며, 주요 원인은 야간 조도 부족과 차량에 의한 포트홀 가림 현상으로 분석되었다. 특히 야간 촬영 시 포트홀의 경계가 흐려지고 대비가 낮아지는 문제가 발생하였으며, 차량 통행으로 인해 포트홀이 일시적으로 시야에서 사라지는 상황에서 탐지 누락이 발생하였다. 이러한 오류를 보완하기 위해 본 연구는 조도 보정을 위한 이미지 전처리 기법을 적용하였다(Fig. 5). 조도 보정 기법을 통해 이미지의 밝기와 선명도는 개선되었으나 포트홀 탐지 정확도에는 유의미한 향상이 나타나지 않았다. 그러나 포트홀은 싱크홀과 달리 한 번에 큰 구멍이 발생하는 것이 아니라 도로표면에 반복되는 충격과 하중이 점진적으로 누적되면서 서서히 확장되는 특성을 지닌다. 따라서 단기적인 야간 촬영이나 악천후 상황에서 탐지 성능이 다소 저하되더라도 포트홀의 발생 및 성장 특성을 고려할 때 즉각적인 탐지보다 지속적 모니터링과 반복적인 관측을 통한 점진적 손상을 추적하는 것이 더 효율적이다.

3.3 차량 트래킹의 정확도

포트홀 탐지 뿐만 아니라, 도로 위험도 평가의 핵심 지표인 차량 통행량 측정을 위해 트래킹 모델의 성능도 정밀하게 검증하였다. 트래킹은 ROI(Region of Interest) 설정과 IOU 기반 객체 추적 알고리즘을 결합하여 수행되었다. 차량 트래킹은 산청 대전-통

영고속도로에 설치 되어있는 한 부분을 화면 녹화를 통해 진행하였다. Fig. 6에서 보이는 파란색 바운딩 박스가 관심영역을 설정한 구간이다. 각 차량은 고유 ID로 구분되며, 이동 경로가 선으로 표시된다. 이를 통해 동일 차량의 중복 카운팅을 방지하고, 차량의 이동 패턴까지도 직관적으로 파악할 수 있다. 관심영역을 설정해 정확도를 올려주었다. 차량이 박스를 통과할 때마다 인공지능을 통해 차량으로 인식해 왼쪽 상단에 초록색으로 되어있는 숫자가 1씩 올라간다. 그렇게 지나가는 차량의 대수를 세어낸다. 화면 녹화 시간을 1분으로 설정한 후 총 30군데 장소를 선정해 실험을 진행하였다. 탐지율이 가장 낮게 나왔을 때는 78.6%로 차량이 총 33대가 지나갔을 때 28대만 탐지한 결과이다. 모든 차량의 대수를 탐지한 장소도 존재했다. 이러한 방식으로 CCTV 30대를 관측해 나온 결과를 평균을 내어 81.48%라는 탐지

**Fig. 6.** AI-Based Vehicle Tracking Process

율이 나왔다.

이는 우수한 트래킹 성능을 의미할 수 있다. 81.48%의 차량 추적 정확도를 의미하며, 평균 속도 추정은 영상 프레임 간의 바운딩 박스 이동 거리를 기반(한국도로공사, 2023)으로 평가하였을 경우 실제 도로 속도 데이터와 비교했을 때 평균 오차는 ± 4.3 km/h로 매우 신뢰성 있는 수준으로 실시간 운영에도 충분한 성능임을 확인할 수 있었다.

4. 결론 및 향후 과제

본 연구는 교통정보 CCTV를 활용하여 도로 포트홀을 자동으로 탐지하고, 교통량 데이터를 기반으로 도로 위험도를 정량화하는 인공지능 기반 포트홀 탐지 및 분석 기법을 제안하였다. 실험 결과, 제안한 포트홀 탐지 모델을 통한 성능평가 결과 탐지 확률은 78.57%로 본 연구에서 목표로 하는 교통정보 CCTV를 통한 포트홀 탐지에 긍정적인 결과를 얻었다. 이는 교통정보 CCTV를 통해 식별 가능한 실제 포트홀을 학습데이터로 추가하여 추가적인 학습을 진행한다면 더 높은 정확도를 기대할 수 있다. 하지만 본 연구는 몇 가지 한계도 존재한다. 첫째, 교통정보 CCTV는 고정형 카메라로서 설치 위치에 따른 시야 제한이 존재하며, 일부 도로 구간은 사각지대에 포함될 수 있다. 둘째, CCTV의 해상도가 제한적이기 때문에 포트홀이 너무 작거나 먼 거리에서는 탐지 정확도가 저하될 가능성이 있다. 셋째, 실험은 주로 맑은 날씨와 주간 조건에서 수행되었으며, 야간, 비, 눈 등 악천후 환경에서의 성능은 충분히 검증되지 않았다. 이러한 환경에서는 조도 저하, 반사광, 영상 품질 열화 등의 문제가 발생할 수 있어 탐지 성능에 영향을 미칠 수 있다.

향후 연구에서는 이러한 한계를 극복하기 위해 몇 가지 방향으로 연구를 확장할 계획이다. 첫째, 드론이나 이동형 카메라를 활용한 다각도 영상 데이터

를 수집하고 이를 기존의 CCTV 영상과 융합하여 시야 제한 문제를 해결하는 방안을 모색할 것이다. 둘째, 포트홀 탐지에서 나아가 균열(Crack), 싱크홀(Sinkhole) 등 도로 전반의 다양한 결함을 포괄적으로 탐지하는 멀티 타겟 분석 모델로 연구를 확장할 예정이다. 셋째, 현재 단순히 포트홀의 존재 여부와 차량 통행량만을 활용한 위험도 평가에서 더 나아가, 포트홀의 면적, 깊이, 위치와 같은 정밀한 물리적 특성을 결합한 정량적 포트홀 위험도 예측 모델을 개발할 계획이다. 이를 통해 사고 발생 가능성을 사전에 예측하고, 도로 유지보수 우선순위 설정의 신뢰성을 더욱 향상시킬 수 있을 것이다. 결론적으로 본 연구는 기존의 수동적이고 국지적인 포트홀 관리 방식을 대체할 수 있는 실시간, 광역, 정량적 도로 결함 탐지 및 분석 시스템의 가능성을 실증하였다. 이러한 기술은 향후 스마트 시티 구축 및 도로 인프라 유지관리의 디지털 전환에 중요한 기여를 할 것으로 기대된다.

참고문헌

1. 국토교통부(2022), 「2022 도로통계연보」, 세종.
2. 한국도로공사(2023), 「도로 결함 및 유지관리 현황 연례 보고서」, 김천.
3. Bhatia, Y., R. Rai, V. Gupta, N. Aggarwal and A. Akula (2022), "Convolutional Neural Networks Based Potholes Detection Using Thermal Imaging", *Journal of King Saud University-Computer and Information Sciences*, 34(3): 578~588.
4. Kim, Y. M., Y. G. Kim, S. Y. Son, S. Y. Lim, B. Y. Choi and D. H. Choi (2022), "Review of Recent Automated Pothole-Detection Methods", *Applied Sciences*, 12(11): 5320.
5. Lee, S. Y., T. H. M. Le and Y. M. Kim (2023), "Prediction and Detection of Potholes in Urban Roads: Machine Learning and Deep Learning Based Image Segmentation Approaches", *Developments in the Built Environment*, 13: 100109.

6. Li, Q., Y. Shi, Q. Liu and G. Liu (2023), "Deep Learning-Based Pothole Detection For Intelligent Transportation: A YOLOv5 Approach", *International Journal of Advanced Computer Science and Applications*, 14(12): 314~321, doi: 10.14569/IJACSA.2023.0141242.
7. Redmon, J., S. Divvala, R. Girshick and A. Farhadi (2016), "You Only Look Once: Unified, Real-Time Object Detection", *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, Las Vegas, NV.
8. Rehan, M., A. Abbas, M. Iftikhar, M. Raza and A. Ahmed (2023), "Pothole Detection for Autonomous Vehicles Using Deep Learning", *Frontiers in Built Environment*, 9, 1323792, doi: 10.3389/fbuil.2023.1323792.
9. Rout, N. K., G. Dutta, V. Sinha, A. Dey, S. Mukherjee and G. Gupta (2023), "Improved Pothole Detection Using YOLOv7 and ESRGAN", *arXiv preprint*, arXiv: 2401.08588, doi: 10.48550/arXiv.2401.08588.
10. Safyari, Y., M. Mahdianpari and H. Shiri (2024), "A Review of Vision-Based Pothole Detection Methods Using Computer Vision And Machine Learning", *Sensors*, 24(17): 5652, doi: 10.3390/s24175652.
11. Saisree, C. and U. Kumaran (2023), "Pothole Detection Using Deep Learning Classification Method", *Procedia Computer Science*, 218: 2143~2152.
12. Terven, J., D. M. Córdova-Esparza and J. A. Romero-González (2023), "A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS", *Machine Learning and Knowledge Extraction*, 5(4): 1680~1716.
13. Yurdakul, M. and Ş. Tasdemir (2025), "An Enhanced YOLOv8 Model for Real-Time and Accurate Pothole Detection and Measurement", *arXiv preprint*, arXiv: 2505.04207, doi: 10.48550/arXiv.2505.04207.
14. Zanevych, Y., V. Yovbak, O. Basytiuk, N. Shakhovska, S. Fedushko and Argyroudis, S. (2024), "Evaluation of Pothole Detection Performance Using Deep Learning Models Under Low-Light Conditions", *Sustainability*, 16(24): 10964.

요 약

노후화가 진행됨에 따라 도로 포트홀 발생 빈도는 지속적으로 증가하고 있으며, 이로 인한 차량 파손 및 교통사고는 중요한 사회적 문제로 대두되고 있다. 그러나 차량 장착 센서나 드론을 활용한 기존 포트홀 탐지 기법은 적용 범위가 제한적이고 구축 비용이 높다는 한계를 가진다. 본 연구에서는 전국 도로에 설치된 교통감시용 CCTV를 활용하여 포트홀을 자동 탐지하는 AI 기반 기법을 제안한다. 제안한 모델은 YOLOv8 인스턴스 세그멘테이션을 적용하여 포트홀을 정밀하게 식별하며, 차량 추적 알고리즘을 결합하여 교통량을 자동 산출한다. 이를 통해 포트홀 규모와 위치, 교통량 정보를 종합적으로 이용하여 도로 위험도를 정량적으로 평가하고 유지관리 우선순위 설정을 지원한다. 제안한 기법은 기존 방법 대비 높은 탐지 정확도와 실시간 처리 성능을 확보하였으며, 도로 인프라 관리의 효율성과 안전성 향상에 기여함을 확인하였다.

주제어: 도로 결합, 포트홀, 포트홀 탐지, 교통정보 CCTV, YOLOv8